

Curso de Procesamiento Digital de Imágenes

Impartido por: Elena Martínez
Departamento de Ciencias de la Computación
IIMAS, UNAM, cubículo 408

http://pcic.iimas.unam.mx/~elena/Teaching/PDI-Lic.html

elena.martinez@iimas.unam.mx

Repaso de Algebra Lineal

Objetivo:

Proveer del material necesario sobre algebra lineal que será de utilidad para los temas del curso de *Procesamiento Digital de Imágenes* que se basan en matrices y vectores.

Material extraído de: www.imageprocessingbook.com

© 2001 Gonzalez & Woods.

Algunas Definiciones

Una *matriz* *m* x *n* (se lee "*m* por *n*"), denotada como **A**, es un arreglo rectangular de entradas o elementos (números, o símbolos que representan números) encerrado típicamente por unos corchetes cuadrados, donde *m* es el número de *filas* y *n* el número de *columnas*.

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

Definiciones

- **A** es *cuadrada* si $m=n$.
- **A** es *diagonal* si todos los elementos fuera de la diagonal son 0, y no todos los elementos de la diagonal son 0.
- **A** es la *matriz identidad* (**I**) si todos los elementos de la diagonal son 1.
- **A** es zero o la *matriz nula* (**O**) si sus elementos son 0.
- La *traza* de **A** es igual a la suma de los elementos de la diagonal principal.
- Dos matrices **A** y **B** son *iguales* si y solo si tienen el mismo número de filas y columnas, y $a_{ij} = b_{ij}$

Definiciones

- La transpuesta $\mathbf{A^T}$, de una matrix **A** de *m* x *n*, es una matriz de *n* x *m* obtenida intercambiando las filas y las columnas de **A**.
- Una martiz cuadrada para la cual $\mathbf{A^T=A}$ se dice que es *simétrica.*
- Cualquier matriz **X** para la cual **XA=I** y **AX=I** se llama *inversa* de **A.**
- Sea *c* un número real o complejo (llamado *escalar*). El *escalar múltiplo* de *c* y de la matriz **A**, denotado como *c***A**, se obtiene multiplicando cada elemento de **A** por *c*. Si *c=-1*, el escalar múltiplo se llama el *negativo* de **A**.

Definiciones

- Un *vector columna* es la matriz *m* x *1* :

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix}$$

- Un *vector fila* es la matriz *1* x *n* :

$$\mathbf{b} = [b_1, b_2, \cdots b_n]$$

Un vector columna puede ser expresado como un vector fila utilizando la transpuesta:

$$\mathbf{a}^T = [a_1, a_2, \cdots, a_m]$$

Operaciones con matrices

- La *suma* de dos matrices **A** y **B** (de igual dimensión), denotada como **A**+**B**, es la matriz con elementos $a_{ij} + b_{ij}$
- La *diferencia* de dos matrices, **A**-**B**, tiene elementos $a_{ij} - b_{ij}$
- El *producto*, **AB**, de una matriz *m* x *n* **A** y *p* x *q* **B**, es una matriz *m* x *q* **C** cuyos *(ij)-ésimo* elemento está formado por la multiplicación de las entradas de la *i-ésima* fila de **A** por las entradas de la *j-ésima* columna de **B**; esto es:

$$c_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{in}b_{pj}$$

Operaciones con matrices

- El *producto interno* (también llamado *producto punto*) de dos vectores:

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix} \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}$$

está definido como:

$$\mathbf{a}^T\mathbf{b} = \mathbf{b}^T\mathbf{a} = a_1b_1 + a_2b_2 + \cdots + a_mb_m = \sum_{i=1}^{m} a_ib_i.$$

Note que el producto interno es un *escalar*.

Vectores y espacios vectoriales

Un *espacio vectoral* se define como un conjunto *V* no vacío de entidades llamadas *vectores* y los escalares asociados a ellos que setisfacen las condiciones que mencionaremos a continuación (de la A a la C). Un espacio vectorial es *real* si los escalares son números reales; es *complejo* si los escalares son números complejos.

Vectores y espacios vectoriales

- Condición A: Existe en *V* una operación llamada *suma de vectores* denotada como **x**+**y**, que satisface:

1. **x**+**y**=**y**+**x** para todos los vectores **x**, **y** en el espacio.
2. **x**+(**y**+**z**)=(**x**+**y**)+**z** para todos **x**,**y**, y **z.**
3. Existe en *V* un único vector llamado el *vector cero*, denotado como **0**, tal que **x**+**0**=**x** and **0**+**x**=**x** para todos los vectores **x.**
4. Para cada vector **x** en *V*, existe un vector único en *V*, llamado la *negación* de **x**, denotado como –**x**, tal que **x**+(-**x**)=**0** y (-**x**)+**x**=**0.**

Vectores y espacios vectoriales

- Condición B: Existe en V una operación llamada *multiplicación por un escalar* que asocia con cada escalar c y cada vector de $\mathbf{x}$ en V, un vector único llamado producto de c y $\mathbf{x}$, denotado como $c\mathbf{x}$ y $\mathbf{x}c$, que satisface:

1. $c(d\mathbf{x})=(cd)\mathbf{x}$ para todo escalar c y d, y todo vector $\mathbf{x}$.
2. $(c+d)\mathbf{x}=c\mathbf{x}+d\mathbf{x}$ para todo escalar c y d, y todo vector $\mathbf{x}$.
3. $c(\mathbf{x}+\mathbf{y})+c\mathbf{x}+c\mathbf{y}$ para todo escalar c y todo vector $\mathbf{x}$ y $\mathbf{y}$.

- Condición C: $1\mathbf{x}=\mathbf{x}$ para todo vector $\mathbf{x}$.

Vectores y espacios vectoriales

Estamos interesados particularmente en *espacios vectoriales reales* de matrices columna reales de *m* x*1*. Denotamos a estos espacios como $\Re^m$, con la suma y multiplicación por escalares definida como lo hicimos anteriormente para las matrices. Los vectores (matrices columna) en $\Re^m$ se escriben como segue:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}$$

Vectores y espacios vectoriales

Ejemplo: El espacio vectorial con el cual nosotros estamos más familiarizados es el espacio vectorial real $\Re^2$, del cual hacemos uso frecuente para la representación gráfica de operaciones con vectores como suma, resta y multiplicación por un escalar, por ejemplo considere dos vectores:

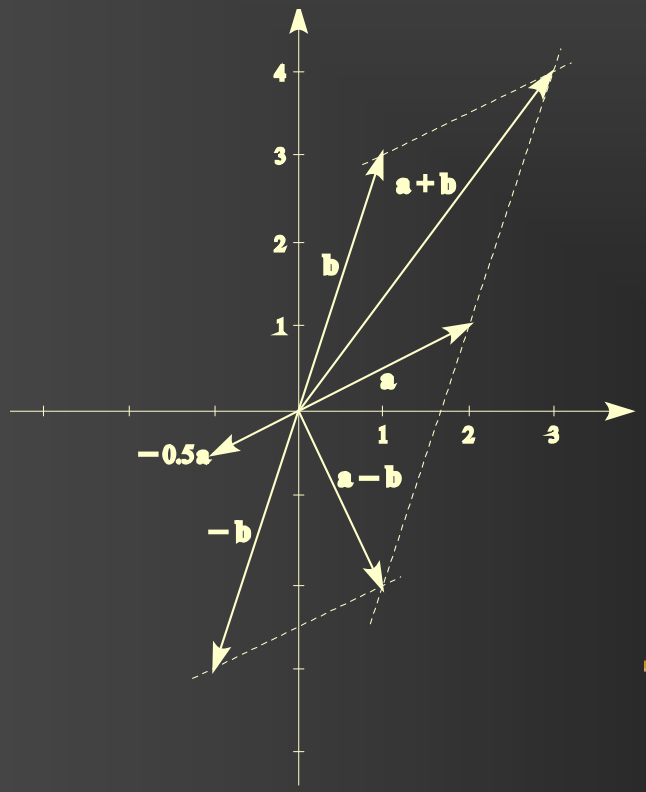
$$\mathbf{a} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \qquad \mathbf{b} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

Utilizando las reglas para la suma y resta de matrices tenemos:

$$\mathbf{a} + \mathbf{b} = \begin{bmatrix} 3 \\ 4 \end{bmatrix} \qquad \mathbf{a} - \mathbf{b} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

Vectores y espacios vectoriales

Ejemplo: La siguiente figura muestra la representación gráfica familiar de las operaciones vectoriales anteriores, así como la multiplicación de un vector **a** por un escalar *c=-0.5*



Vectores y espacios vectoriales

Considere dos espacios vectoriales V_0 y V tal que:

- Cada elemento de V_0 es también un elemento de V (i.e. V_0 es un *subconjunto* de V).
- Las operaciones sobre los elementos de V_0 son las mismas que sobre los elementos de V. Bajo estas condiciones, V_0 se dice que es un *subespacio* de V.

Una *combinación lineal* de $\mathbf{v_1}$, $\mathbf{v_2}$, …, $\mathbf{v_n}$, es una expresión de la forma:

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_n \mathbf{v}_n$$

Donde los α's son escalares

Vectores y espacios vectoriales

Se dice que un vector **v** es *linealmente dependiente* de un conjunto, *S*, de vectores $\mathbf{v}_1$, $\mathbf{v}_2$, …, $\mathbf{v}_n$ sí y sólo sí **v** puede ser escrito como una combinación lineal de esos vectores. De otra manera, **v** es *linealmente independiente* del conjunto de vectores $\mathbf{v}_1$, $\mathbf{v}_2$, …, $\mathbf{v}_n$.

Vectores y espacios vectoriales

Un conjunto, *S*, de vectores $\mathbf{v_1}$, $\mathbf{v_2}$, …, $\mathbf{v_n}$ en *V* se dice que se *genera* un subespacio V_0 de *V* , sí y sólo sí *S* es un subconjunto de V_0 y cada vector $\mathbf{v_0}$ en V_0 es linealmente dependiente de los vectores en *S*. El conjunto *S* se dice que es un *conjunto generador* de V_0. La base de un espacio vectorial *V* es un conjunto generador linealmente independiente de *V*. El número de vectores en la base para un espacio vectorial se llama la *dimensión* del espacio vectorial. Si por ejemplo, el número de vectores de la base es *n*, decimos que el espacio vectorial es *n*-dimensional.

Vectores y espacios vectoriales

Un aspecto importante de los conceptos previamente discutidos recae en la representación de cualquier vector en $\Re^m$ como una combinación lineal de vectores base. Por ejemplo, cualquier vector:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

en $\Re^3$ puede ser representado como una combinación lineal de vectores base:

$$\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \text{and} \quad \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

Norma de un vector

La *norma de un vector* en un espacio vectorial V es una función que asigna a cada vector $\mathbf{v}$ en V un número real no-negativo, llamado norma de v, denotado como $\|\mathbf{v}\|$. Por definición, la norma satiface las siguientes condiciones:

1. $\|\mathbf{v}\| > 0$ para $\mathbf{v} \neq 0$; $\|\mathbf{0}\| = 0$;
2. $\|c\mathbf{v}\| = |c|\,\|\mathbf{v}\|$ para todo escalar c y vector $\mathbf{v}$, y
3. $\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|$.

Norma de un vector

Existe un gran número de normas que se utilizan en la práctica. En nuestro trabajo, la norma que se utiliza con más frecuencia es la llamada *2-norma*. Para un vector **x** en los reales $\Re^m$ es:

$$\|\mathbf{x}\| = [x_1^2 + x_2^2 + \cdots + x_m^2]^{1/2}$$

esta norma se conoce como la *distancia Euclideana* desde el origen a un punto **x**; lo anterior da a la expresión el nombre familiar de *norma Euclideana*. La expresión también se conoce como el tamaño de un vector **x**, desde origen en el punto **0**. Por lo que esta norma también se puede escribir como:

$$\|\mathbf{x}\| = [\mathbf{x}^T\mathbf{x}]^{1/2}$$

Norma de un vector

La desigualdad de *Cauchy-Schwartz* establece que:

$$|\mathbf{x}^T\mathbf{y}| \leq \|\mathbf{x}\|\,\|\mathbf{y}\|$$

Otro resultado bien conocido que utilizaremos es la expresión:

$$\cos\theta = \frac{\mathbf{x}^T\mathbf{y}}{\|\mathbf{x}\|\,\|\mathbf{y}\|}$$

Donde θ es el ángulo entre los vectores **x** y **y**. De estas dos expresiones sigue que el producto interno entre dos vectores:

$$\mathbf{x}^T\mathbf{y} = \|\mathbf{x}\|\,\|\mathbf{y}\|\cos\theta$$

Por lo tanto, el producto interno puede ser expresado como una función de las normas de vectores y del ángulo entre ellos.

Norma de un vector

Del resultado anterior, dos vectores en $\Re^m$ son *ortogonales* sí y sólo sí su producto interno es *cero*. Dos vetores son *ortonormales* si, además de ser *ortogonales*, el tamaño de cada vector es igual a 1.

De lo anterior, vemos que un vector arbitrario **a** se vuelve un vector $\mathbf{a}_n$ de tamaño unitario realizando la siguiente operación: $\mathbf{a}_n = \mathbf{a} / \| \mathbf{a} \|$ Claramente entónces, $\| \mathbf{a}_n \| = 1$.

Se dice que un *conjunto de vectores* es un conjunto *ortogonal* si cada dos vectores en el conjunto son ortogonales. Un *conjunto de vectores* es *ortonormal* si cada dos vectores en el conjutno son ortonormales.

Algunos aspectos importantes de la ortogonalidad

Sea $B=\{\mathbf{v_1}, \mathbf{v_2}, \ldots, \mathbf{v_n}\}$, una base ortogonal u ortonormal en el sentido definido previamente. Un resultado importante en el análisis vectorial es que un vector **v** puede ser representado con respecto a la base ortogonal *B* como:

$$\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_n \mathbf{v}_n$$

donde los coeficientes están dados por:

$$\alpha_i = \frac{\mathbf{v}^T \mathbf{v}_i}{\mathbf{v}_i^T \mathbf{v}_i} = \frac{\mathbf{v}^T \mathbf{v}_i}{\|\mathbf{v}_i\|^2}$$

Ortogonalidad

La clave importante de este resultado es que, si representamos un vector como una *combinación lineal de vectores bases ortogonales u ortonormales*, podemos determinar directamente los coeficientes simplemente calculando los productos internos. Es posible convertir un conjunto generador de vectores linealmente independientes en un conjunto generador ortogonal por medio de un proceso conocido como *Gram-Schmidt*. Existe un gran número de programas que implementan el proceso *Gram-Schmidt* y procesos similares, así que no entraremos en detalles, y se deja al lector su investigación.

Eigenvalores & Eigenvectores

Defínción: Los *eigenvalores* de una matriz real **M** son los *números reales* λ para los cuales existe un vector *no-cero* **e** tal que: $\mathbf{Me} = \lambda\,\mathbf{e}$

Los *eigenvectores* de **M** son *los vectores no-cero* **e** para los cuales existe un número real λ tal que: $\mathbf{Me} = \lambda\,\mathbf{e}$.

Si $\mathbf{Me} = \lambda\,\mathbf{e}$, para $e \neq 0$, entónces **e** es un *eigenvector* de **M** asociado con un *eigenvalor* λ , y viceversa. Los eigenvectores y sus correspondientes eigenvalores de **M** constituyen el *eigensistema* de **M.**

Eigenvalores & Eigenvectores

Ejemplo: Considere la matrix

$$\mathbf{M} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$

Es fácil de verificar que $\mathbf{M}\mathbf{e}_1 = \lambda_1\mathbf{e}_1$ y $\mathbf{M}\mathbf{e}_2 = \lambda_2\mathbf{e}_2$ para $\lambda_1=1$, $\lambda_2=2$ y

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{y} \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

En otras palabras, $\mathbf{e}_1$ es un eigenvector de $\mathbf{M}$ con el eigenvalor asociado λ_1, y similarmente para $\mathbf{e}_2$ y λ_2.

Eigenvalores & Eigenvectores

Las siguientes propiedades que damos aquí son *sin prueba!*, y son un antecedente escencial en el uso de vectores y matrices para el procesamiento digital de imágenes. En cada caso, asumimos una matriz real de orden m x n aunque, como se ha establecido anteriormente, estos resultados se aplican igualmente a números complejos.

1. Si $\{\lambda_1, \lambda_2, \ldots, \lambda_q\}$ $q \leq m$, es un conjunto eigenvalores distintos de **M**, y $\mathbf{e}_i$ es un eigenvector de **M** con eigenvalores correspondientes λ_i, $i = 1,2,\ldots,q$, entónces $\{\mathbf{e}_1,\mathbf{e}_2,\ldots,\mathbf{e}_q\}$ es un conjunto linealmente independiente de vectores. Una implicación importante de esta propiedad es que : Si una matriz **M** de m x n tiene m eigenvalores distintos, sus eigenvectores constituirán un conjunto ortogonal (ortonormal), lo que significa que cualquier vector m-dimensional puede ser expresado como una combinación lineal de eigenvectores de **M.**

Eigenvalores & Eigenvectores

2. Los números a lo largo de la diagonal principal de una matriz diagonal son igual a sus eigenvalores. No es difícil de demostrar utilizando la definición $\mathbf{Me} = \lambda\mathbf{e}$ que los eigenvectores pueden ser escritos por inspección cuando **M** es diagonal.

3. Una matriz **M** simética y real de tamaño m x m tiene un conjunto de m eigenvectores linealmente independientes que pueden ser elegidos para formar un conjunto *ortonormal*. Esta propiedad es de particular importancia cuando trabajamos con matrices de *covarianza* (que se verán cuando repasemos probabilidad) las cuales son reales y simétricas.

Eigenvalores & Eigenvectores

4. Un corolario de la Propiedad 3 es que los eigenvalores de una matriz real y simétrica *m* x *m*, y sus eigenvectores asociados pueden elegirse para formar un conjunto ortonormal de *m* vectores.

5. Supóngase que **M** es una matriz de *m* x *m* real y simétrica, y que formamos la matriz **A** cuyas filas son los *m* eigenvectores ortonormales de **M**. Entónces, el produto $\mathbf{AA}^T=\mathbf{I}$ porque las filas de **A** son vectores ortonormales. Por lo tanto, se ve que $\mathbf{A}^{-1}=\mathbf{A}^T$ cuando **A** está formada de esta manera.

6. Considere las matrices **M** y **A** de 5. El producto $\mathbf{D}=\mathbf{AMA}^{-1}=\mathbf{AMA}^T$ es una matriz diagonal cuyos elementos en la diagonal principal son los eigenvalores de **M**. Los eigenvectores de **D** son los mismo que los engienvectores de **M**.

Eigenvalores & Eigenvectores

Ejemplo: Supónga que tenemos una población de vectores aleatorios, denotados por **{x}**, con la matriz de covarianza:

$$\mathbf{C}_\mathbf{x} = E\{(\mathbf{x} - \mathbf{m}_\mathbf{x})(\mathbf{x} - \mathbf{m}_\mathbf{x})^T\}$$

Supónga que realizamos una transformación de la forma **y=Ax** en cada vector **x**, donde las filas de **A** son los eigenvectores ortonormales de $\mathbf{C}_\mathbf{x}$. La matriz de covarianza de la población **{y}** es:

$$\begin{aligned}
\mathbf{C}_\mathbf{y} &= E\{(\mathbf{y} - \mathbf{m}_\mathbf{y})(\mathbf{y} - \mathbf{m}_\mathbf{y})^T\} \\
&= E\{(\mathbf{Ax} - \mathbf{Am}_\mathbf{x})(\mathbf{Ax} - \mathbf{Am}_\mathbf{x})^T\} \\
&= E\{\mathbf{A}(\mathbf{x} - \mathbf{m}_\mathbf{x})(\mathbf{x} - \mathbf{m}_\mathbf{x})^T\mathbf{A}^T\} \\
&= \mathbf{A}E\{(\mathbf{x} - \mathbf{m}_\mathbf{x})(\mathbf{x} - \mathbf{m}_\mathbf{x})^T\}\mathbf{A}^T \\
&= \mathbf{AC}_\mathbf{x}\mathbf{A}^T
\end{aligned}$$

Eigenvalores & Eigenvectores

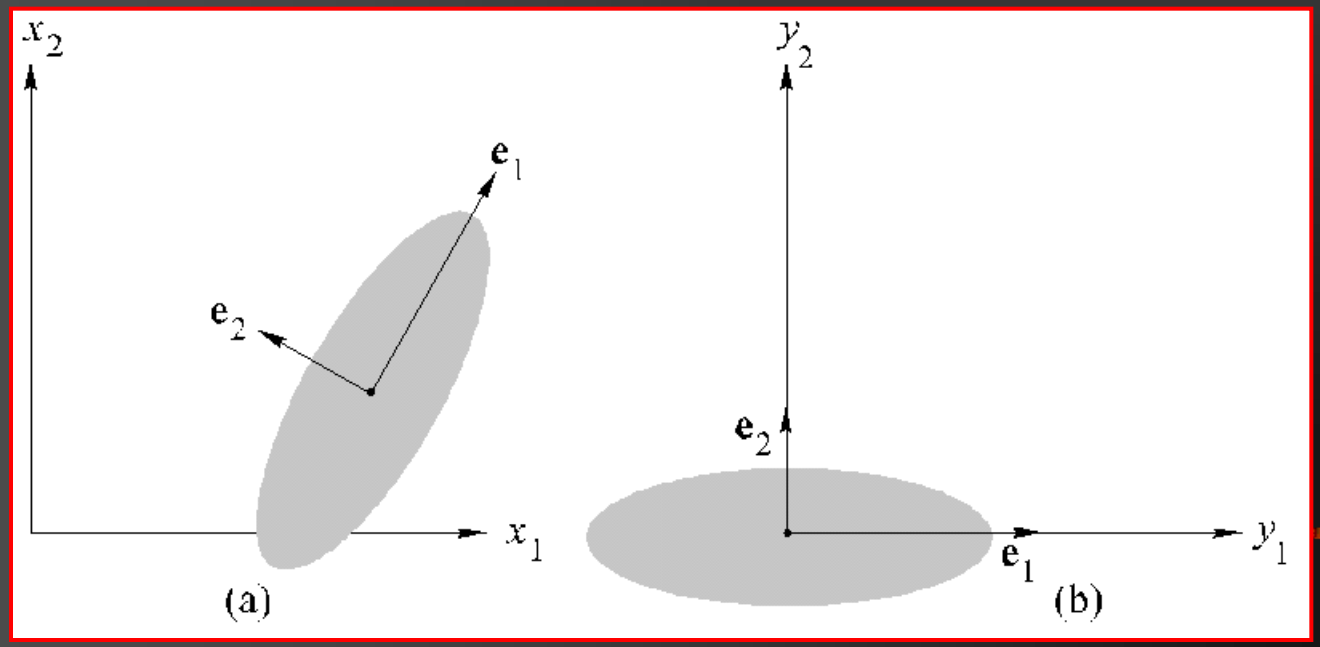
De la Propiedad 6, sabemos que $\mathbf{C_y}=\mathbf{AC_xA}^T$ es una matriz diagonal con los eigenvalores de $\mathbf{C_x}$ a lo largo de la diagonal principal. Los *elementos de la diagonal principal* de una matriz de covarianza son *las varianzas de los componentes de los vectores* de la población. Los elementos *fuera de la diagonal* son las *covarianzas de los componentes* de estos vectores.

El hecho de que C_y sea diagonal significa que los elementos de los vectores en la población $\{\mathbf{y}\}$ no están correlacionados (sus covarianzas son 0). Por lo tanto, vemos que la aplicación de la transformación lineal $\mathbf{y=Ax}$ que involucran a los eigenvectores de C_x decorrelaciona los datos, y los elementos C_y a lo largo de su diagonal principal dan las varianzas de los componentes de las $\mathbf{y}$ a lo largo de los eigenvectores.

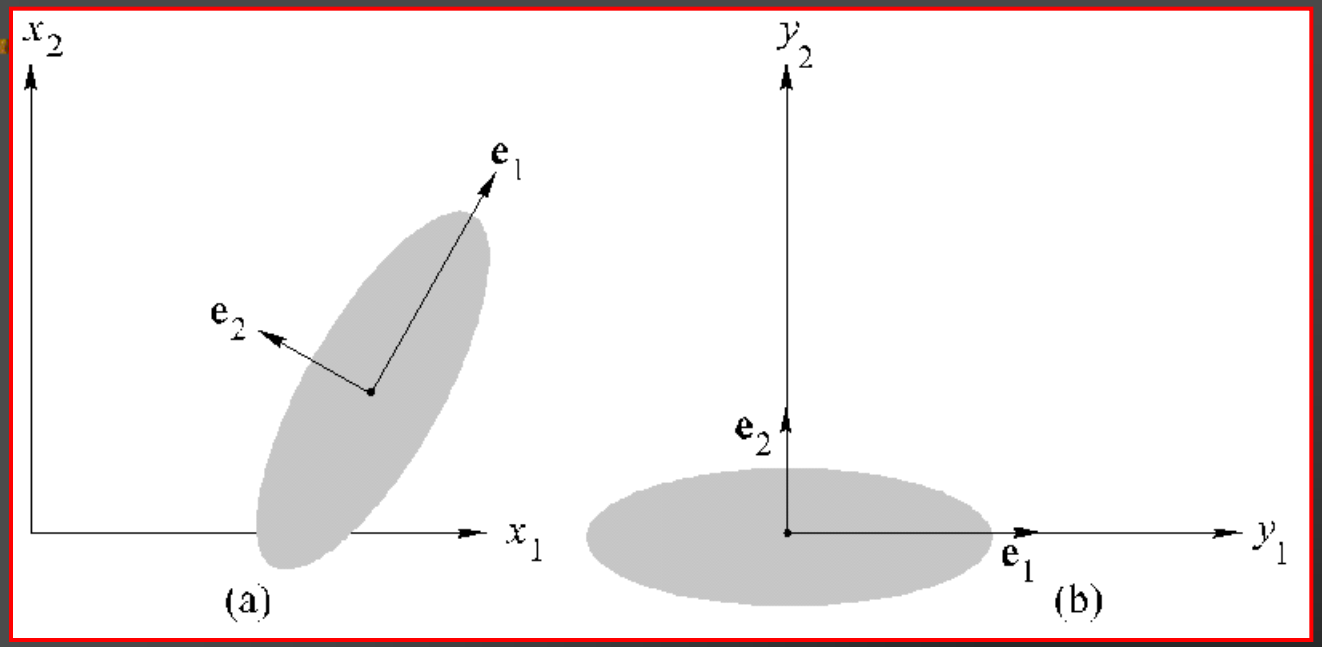
Eigenvalores & Eigenvectores

Básicamente lo que hemos conseguido es una *transformación de coordenadas* que alinean los datos a lo largo de los eigenvectores de la matriz de covarianza de la población.

Los conceptos anteriores, se ilustran en la siguiente figura:

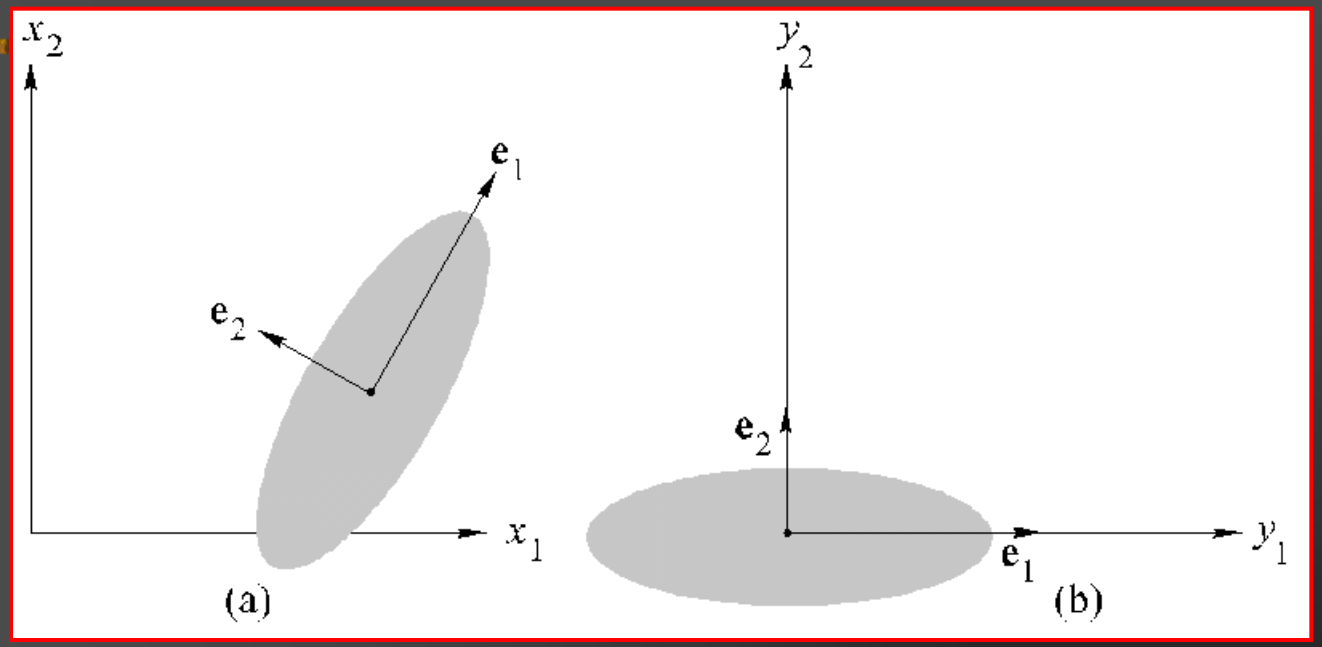


Eigenvalores & Eigenvectores



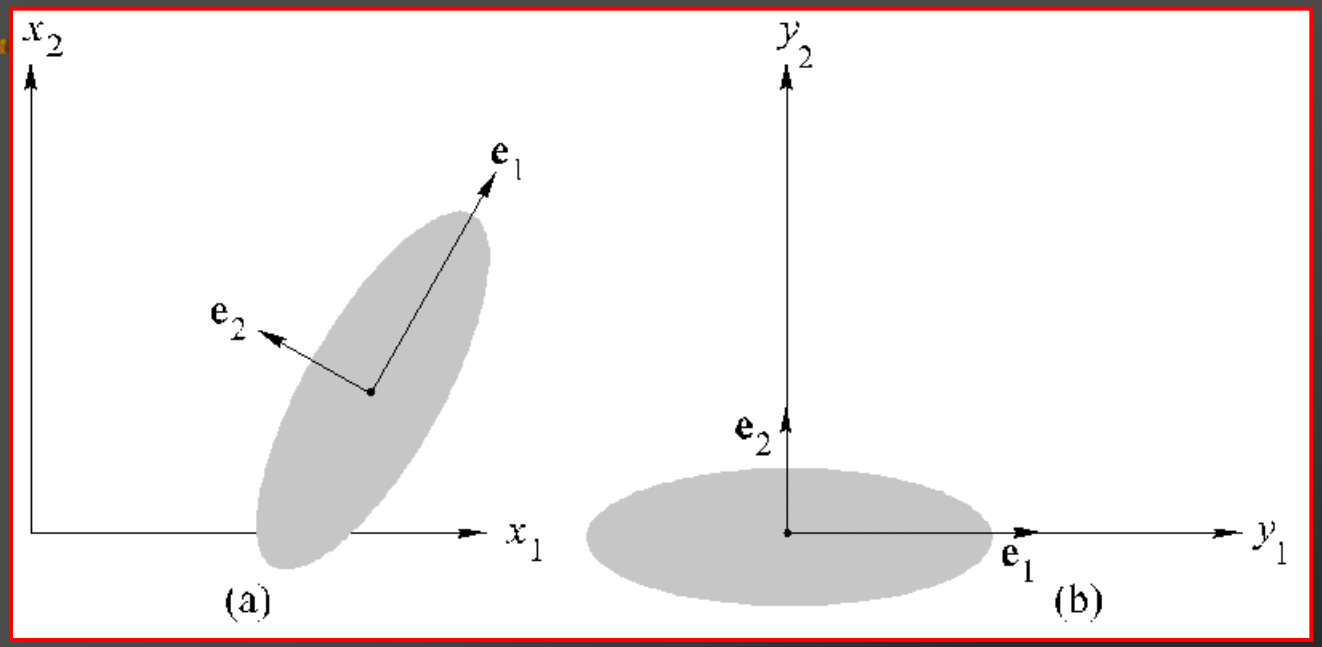
La parte (a) muestra la población {**x**} en dos dimensiones junto con los eigenvectores $\mathbf{C_x}$ (los puntos negros son los promedios). El resultado de realizar la transformación $\mathbf{y=A(x-m_x)}$ en las **x** se muestra en la parte (b) de la figura.

Eigenvalores & Eigenvectores



El hecho de sustraer el promedio de las **x** causa que las **y** tengan promedio igual con *cero*, por lo que la población está centrada en el origen del sistema coordenado de los datos transformados. Es importante notar que todo lo que hemos hecho aqui es hacer a los *eigenvectores el nuevo sistema coordenado* (y_1,y_2).

Eigenvalores & Eigenvectores



Debido a que la matriz de covarianza de las **y** es diagonal, ésto decorrelaciona los datos. El hecho de que la mayoría de los datos esté distribuído a lo largo de $\mathbf{e}_1$ es debido a que las filas de la matriz de transformación **A** se eligieron de acuerdo al orden de los eigenvalores, teniendo en la primera fila al mayor de ellos.



Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas (IIMAS)

http://pcic.iimas.unam.mx/~elena/Teaching/PDI-Lic.html